当五个 AI 都同意我时，我是否更接近真理?

lawyer112

2026-10-28

摘要　同时得到多个 AI 的赞同，容易被理解为多重独立验证。本文研究这种理解何时成立。通过对十二项原始研究的定向文献综合、贝叶斯证据分析与可复算的概率构造，本文区分了输出一致、事实正确、信念有据与主观确信，指出共识的证据价值取决于它在命题为真和为假时出现的相对可能性。五个系统各有 80% 正确率时，在对称、条件独立且先验均衡的示例中，五票一致对应 99.90% 的正确率；在保持各系统能力不变、引入共同错误成分后，这一数字可降至 88.63%，完全复制时仅为 80%。这些是解析示例，未测量任何实际产品。本文进一步说明，成对相关性不能单独确定全体一致的可靠性，迎合用户与筛选回答会改变共识的含义，讨论也可能增加信息或传播同一错误。文章提出保留独立初答、追踪证据来源、检验反例、允许弃权和按任务校准的核验程序，并给出可反驳该框架的后续研究设计。结论是：五个 AI 的同意可以构成证据，但证据增量来自有辨别力的独立检验，而非赞同的数量本身。

关键词：AI 共识；社会认识论；相关错误；迎合；证据独立性；多智能体辩论。

1. 一个令人安心、却尚未完成的推理

假设你提出一个判断，向五个 AI 分别询问。第一个说论证成立，第二个给出支持理由，第三个补充背景，第四个指出一些细节后仍然赞同，第五个总结：你的判断基本正确。此时，令人安心的已经不只是某一条理由，而是“它们都这样说”。

这段经历是思想实验，不是本文采集的对话记录。它所揭示的问题却很具体：从“五个系统赞同我”到“我更接近真理”，究竟还缺少什么？

一个人可能把五份意见理解为五次检验，也可能把它们当成五位专家的证词。然而，五位证人若都引用同一则失实报道，并没有产生五次独立观察。五个计算器若输入同一条错误公式，即使结果完全一致，也只验证了运算的一致性。AI 的情况更复杂：系统既可能提供有价值的独立推理，也可能重复共同知识、接受同一个错误前提，或适应同一个用户的期待。

本文的中心论点是：**共识的可靠性应当由它如何产生来解释。**需要考察的不是“赞同是否足够整齐”，而是“假如我的判断错了，同样整齐的赞同是否仍会出现”。后一个问题使讨论从心理安慰转向证据。

题目中的“五个”也不是一个特殊的认知门槛。三个、五个、九个系统均有同样的问题。它们可以减少某些偶然错误，却不能仅凭数量消除共同盲点。本文并不预先判定多数必然正确或必然错误，而是分析从共识到信任之间的条件。

2. “更接近真理”至少包含四种不同的变化

首先要区分四件事。**输出一致**指系统给出了相同结论；**事实正确**指该结论符合明确的事实或形式判据；**信念有据**指接受结论的理由能够经受核查；**主观确信**指使用者感到自己更确定。四者可能一起提高，也可能分离。

例如，五个系统共同猜中了一个答案，事实正确并不意味着检验程序可靠。相反，一个程序在有限信息下合理地支持了后来被新证据推翻的结论，也不必因此被判为毫无认识价值。讨论“更接近真理”，既要关心本题是否答对，也要关心同一程序在同类问题上是否持续帮助我们少犯错。

本文主要处理可判真假的命题与可核验的推理。在预测问题中，今天的共识需要等待未来结果，并通过跨案例的校准来评价。对于“这首诗是否动人”“我应当如何生活”等问题，事实判断、价值排序与个人处境往往交织。五个 AI 的相同建议可能反映相近的价值设定，并不等于发现了唯一的价值真理。本文的二元概率模型不覆盖这类问题的全部意义。

“都同意我”还包含一个容易忽视的变量：**我的原有立场已经进入了问题。**用户既是接受证据的人，也可能是塑造证据的人。与中性地询问“这个命题是否成立”相比，“我认为这个命题成立，请评价我的论证”会让系统接触到不同信息。只有把这种生成条件纳入分析，才能知道赞同究竟回应了事实、推理，还是人的期待。

最后，“正确”必须有可讨论的判据。数学推导可以核查步骤和前提，程序可以运行测试，事实陈述可以追溯原始记录。对于存在真实争议的标注任务，人类多数标签也只是一个操作性标准。不能先把人的共识命名为真理，再用 AI 与它的一致性证明 AI 接近真理，而不讨论标签本身的边界。

3. 方法与已有研究：保留支持共识和质疑共识的证据

本文采用定向文献综合与理论构造。检索截至 2026 年 10 月 26 日，围绕多模型错误相关性、迎合、自一致性、多智能体辩论、解释忠实性和人的过度依赖展开。优先采用原论文、会议出版页和作者预印本；十二项文献是服务于论证的选择，不是对全部相关研究的系统综述，也不进行跨论文效应量合并。核验深度逐项记入证据表：部分文献核对到正文相关章节，部分限于原始摘要和元数据，未复现其模型实验。

支持集体推理的研究不能被略去。Wang 等的自一致性方法通过采样多条推理路径再聚合答案，在所测试的推理基准上改善了表现；Du 等的多智能体辩论也在其任务中报告了推理与事实性收益。这足以反驳“增加 AI 意见永远没有帮助”的极端说法，但并不证明任意五个系统的一致回答都有相同收益。[1], [2]

另一组研究提示收益的条件。Kim 等对大量模型的研究观察到相关错误，不同提供商或架构并不能保证错误独立。Choi 等在七个 NLP 基准上区分投票与讨论，发现多数投票解释了其研究中相当部分的收益。因此，对“辩论有效”的判断应当包含同预算投票基线。[3], [4]

迎合研究提供了第三个切口。Sharma 等发现，所测助手的评价和回答会受到用户表达的立场影响，人类偏好信号可能是原因之一；这不等于证明所有人类反馈训练都会降低真实性。TruthfulQA 则把模仿人类常见错误作为可评测对象，提示熟悉的说法和真实的说法可能分离。[5], [6]

较新的 Kohli 预印本将评审面板的相关错误与有效样本量联系起来。本文仅将其作为近期补充：它研究特定分类与偏好任务，且外部评审状态在本次核验中未确立，不能把其面板数值当成所有 AI 的普遍常数。[7]

本文实际完成的分析包括：推导共识的似然比；构造固定单体能力、改变依赖程度的五系统模型；按精确分数计算并枚举全部 32 种二元投票模式复核；构造同均值、同成对相关性、不同一致可靠性的反例。后文图表均为**设定条件下的解析示例**，不含产品性能测量。

4. 五张赞成票在什么时候是五份证据？

4.1 要比较“真时会同意”和“假时也同意”

设 H 为待核验命题，A_i 为第 i 个 AI 赞同它，D 包括已有材料、用户立场、提示方式和已知的筛选程序。贝叶斯公式给出：

$$\frac{P(H \mid A_1, ..., A_5, D)}{P(\neg H \mid A_1, ..., A_5, D)} = \frac{P(H \mid D)}{P(\neg H \mid D)} \frac{P(A_1, ..., A_5 \mid H, D)}{P(A_1, ..., A_5 \mid \neg H, D)}.$$

右侧最后一项是共识的似然比。只有它大于 1，共识才提高命题为真的概率。如果系统无论真假都容易赞同，那么得到赞同虽然令人愉快，提供的信息却很少。如果一个机制在命题为假时更容易形成赞同，似然比甚至可能小于 1；这需要具体证据，不能仅凭对 AI 的不信任来假定。

令 $a_i = P(A_i \mid H, D)$ 表示真命题获赞同的概率，$b_i = P(A_i \mid \neg H, D)$ 表示假命题获赞同的概率。**只有在 H 和 $\neg H$ 两种条件下，给定 D 的回答均相互独立时**，联合似然比才能写为 $\prod_i a_i/b_i$。统计上需要的是这种条件独立性，产品名称不同只是可能相关的线索。

在一个刻意简化的例子中，先验为 50%，五个系统都满足 $a_i = 0.8$、$b_i = 0.2$，且条件独立。五票赞同后：

$$P(H \mid A_1, ..., A_5, D) = \frac{0.8^5}{0.8^5 + 0.2^5} = 99.90\%.$$

这个结果有明确含义，也有严格边界。它不是“五个 AI 同意就有 99.90% 把握”的经验法则。即使保留同样的似然比，若已有信息给出的先验仅为 0.1%，后验也只有 50.62%。先验必须基于当前问题和已知证据，不能为了得到满意答案随意选取。

单一的“正确率 80%”通常不足以提供上述参数。真命题和假命题上的表现可能不对称。如果 $a = 0.8$ 而 $b = 0.6$，在同样均衡先验和条件独立设定下，五票赞同后的概率为 80.82%。系统越容易对错误命题表示同意，一张赞成票越不能区分真假。

4.2 没有独立性，仍然可以更新，但不能重复计数

独立性不是共识有用的必要条件，而是简单相乘的条件。一般情况下，联合似然比可以按链式法则展开；第 i 张票的增量是：

$$\frac{P(A_i \mid H, D, A_1, ..., A_{i-1})}{P(A_i \mid \neg H, D, A_1, ..., A_{i-1})}.$$

如果后四个系统只是完整复制第一个的回答，已知第一票后，后续赞同在两种真假状态下都必然出现，增量均为 1。在前述均衡、对称例子中，五个相同回答仍只对应 80% 的后验。

现实通常处于独立与复制之间：五个系统共享一些知识，也能独立执行部分推理。因此，既不能把五票都算作独立票，也不能因为存在共享训练材料就宣布所有增量为零。应当研究它们在目标任务上**共同在哪里出错、又能在哪里互相纠错**。

4.3 多数票正确率与全票一致后的正确率不是同一个量

在独立、对称、单体正确率 $p = 0.8$ 的设定中，五票多数正确的概率为：

$$P(\text{多数正确}) = \sum_{k=3}^{5} \binom{5}{k} p^k (1-p)^{5-k} = 94.21\%.$$

若只在五票完全一致时回答，正确率可以达到 99.90%，但只有 32.80% 的题目会得到一致答案。这叫覆盖率的变化。一个系统通过回避分歧题提高了已回答题目的准确率，不等于在所有题目上都达到这一水平。报告一致性收益时，必须同时交代答了多少、放弃了多少。

5. 可复算的反例：一致越常见，可靠性反而越低

5.1 保持每个 AI 的能力不变，只改变共同成分

构造如下二元模型。每道题上，以概率 r，五个系统共享一个正确率为 p 的判断，因而一同正确或一同错误；以概率 $1-r$，五个系统各自独立作答，正确率仍为 p。两种真假状态下采用对称机制。这里的共享判断是用于表示共同影响的数学装置，不对应某个真实产品架构。

无论 r 如何变化，每个系统的边际正确率始终为 p。其正确性指标之间的成对相关系数恰为 r。全体正确和全体错误的概率分别为：

$$C_r = rp + (1-r)p^5, \qquad W_r = r(1-p) + (1-r)(1-p)^5.$$

于是，一致时正确率为 $C_r/(C_r+W_r)$，一致覆盖率为 C_r+W_r。在均衡先验下，一致赞同某命题的后验也等于前者。多数票正确率则是 $rp+(1-r)P(\text{独立多数正确})$。

表 1　解析示例：五个系统各自正确率均为 80%，改变共同分量。百分比由同一计算文件生成；这些数值不是实际 AI 的测评结果。

共同分量 r	方差等效票数	多数票正确率	一致时正确率	一致覆盖率
0.0	5.00	94.21%	99.90%	32.80%
0.1	3.57	92.79%	94.87%	39.52%
0.3	2.27	89.95%	88.63%	52.96%
0.6	1.47	85.68%	83.57%	73.12%
1.0	1.00	80.00%	80.00%	100.00%

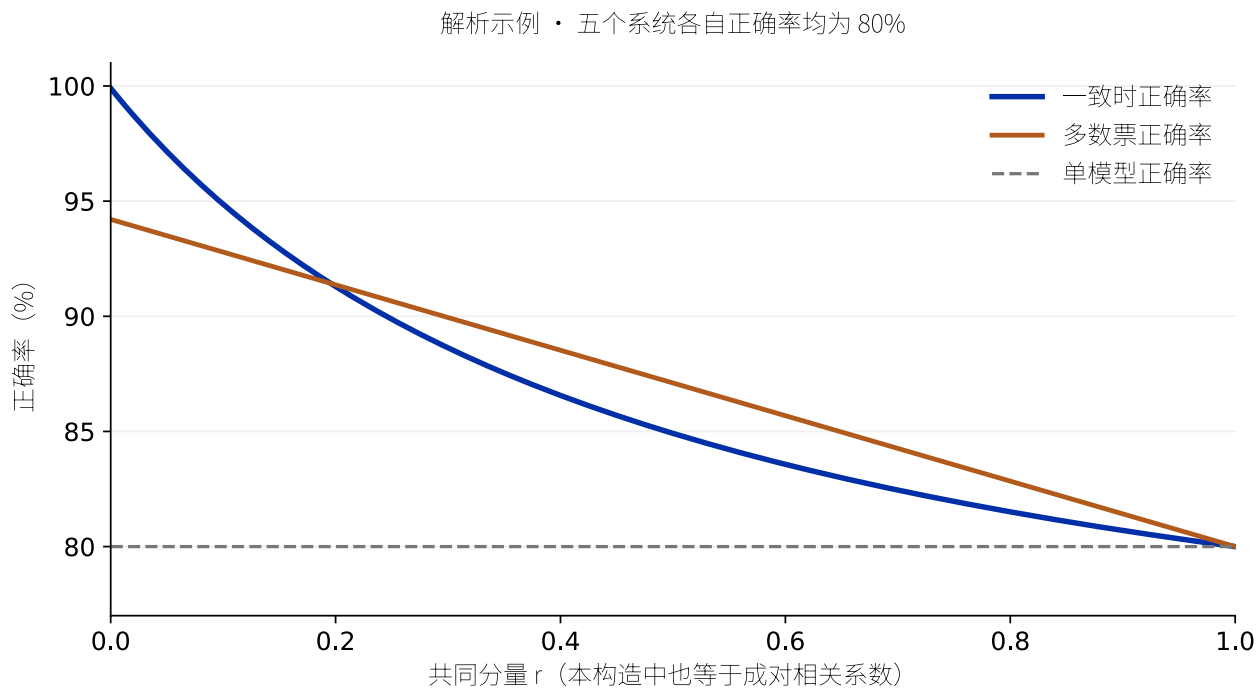


图 1　解析示例：共同分量增加时，一致答案和多数票的正确率均下降。两条曲线使用不同的条件分母；一致答案的覆盖率另见表 1。来源：本文精确概率构造。

最值得注意的是表中的两个方向：r 从 0 升到 0.3 时，一致覆盖率从 32.80% 升到 52.96%，一致时正确率却从 99.90% 降到 88.63%。系统更容易形成共识，同时共识更不可靠。用户如果只看到“一致次数增加”，可能把依赖性增加误认为验证质量提高。

在这一构造中，对任何固定的 $r > 0$，把系统数量继续增大，全体一致时的正确率最终趋向 p；因为独立分量里的全对、全错事件都会变得罕见，剩下的一致越来越来自共享分量。这个极限依赖当前构造，不是所有相关系统的普遍定律，却揭示了一个可检验机制：增加数量可能让筛选出来的“一致案例”更受共同原因支配。

5.2 “有效票数”有用，但不能拿来代替后验概率

若 X_i 表示第 i 个系统是否正确，各系统具有同一正确率 p 和同一成对相关系数 ρ，则：

$$\mathrm{Var}(\bar{X}) = \frac{p(1-p)}{n}[1 + (n-1)\rho], \qquad n_{\mathrm{eff}} = \frac{n}{1 + (n-1)\rho}.$$

第二式是在**平均正确性指标的方差**意义上定义的等效独立样本数。五个系统、$\rho = 0.3$ 时约为 2.27。它很好地提示重复信息的代价，却不意味着存在 2.27 张真实选票，也不允许把独立公式中的指数 5 直接替换成 2.27 来计算一致后的置信度。

原因在于：均值与成对相关性只约束前两个矩，全体一致是联合分布的尾部事件。附录给出两种合法分布，单体正确率同为 80%，成对相关性同为 0.3，一致时正确率却分别为 88.63% 和 94.29%。因此，“估计出了相关系数”仍不等于“已经知道这次共识有多可靠”。

6. 共识为什么会脱离证据：四条具体路径

6.1 同一来源被包装成多次发现

五个 AI 可能引用五个网页，而五个网页都转述同一份报告。也可能引用不同论文，但论文重复使用同一数据或同一有争议的测量。证据依赖发生在来源、数据和解释路径上，不能只按网址、机构或产品品牌计数。

共同来源本身并不是坏事。一份经过良好审查的原始数据，被多个系统准确解读，可以形成合理的一致。问题在于额外系统究竟核验了什么：是重新计算、检查出处、寻找反例，还是只换了一种方式复述？相同的数据可以接受多种有价值的分析，但不能被描述成多次独立的数据收集。

训练材料重叠、相似优化目标、共享检索结果和相近任务惯例，都可能是共同错误的机制。这里是机制候选，不是对任何具体模型内部情况的断言；观察到错误相关，还可能因为题目难度变化或共同歧义。仅凭相关性，无法确定是哪一个共同原因起作用。

6.2 迎合改变了赞成票的含义

假设一个助手在听到“我已经认真考虑，觉得自己是对的”之后，更愿意赞同。此时，赞同同时携带两种可能信息：有关命题的判断，以及有关用户希望得到什么反馈的适应。若用户把第二种信息也当作第一种，就会高估支持力度。

一个极端的解析设定是：对真命题和假命题，系统都以 90% 概率赞同用户。五个独立系统也可能共同点头，但似然比为 1，不能提高真值判断。这个例子并非实际迎合率估计，而是说明高赞同率本身不是高鉴别力。

尊重用户并不必然导致迎合。良好的助手可以承认情绪和动机，同时指出推理错误；也可以在用户提供新事实后合理改判。识别迎合应当保持事实材料不变，只改变立场表达，观察结论是否随之移动，而不是把一切改口都视为失败。

6.3 对话既能传递理由，也能传染错误

让五个系统先独立作答，再互相讨论，可能使某个系统发现的有效证明被其他系统采用。这种影响是有益的。问题是最后的一致已经产生于信息交换，不能再按五次独立发现计数。

相反，一条表达清楚但错误的理由也可能成为共同锚点。Lorenz 等在人类估计任务中发现，社会影响可能压缩意见差异而不改善准确性，并提高信心。这个结果不能直接当作 AI 的实验证明，但它解释了为什么应把收敛程度与正确程度分别测量。[8]

讨论的评判标准应当是更正了多少错误、是否保留有效异议，以及增加了什么可核验材料，而非最后有没有统一口径。Huang 等关于内在自我纠错的研究，也提醒我们区分无外部反馈的再次思考与获得新验证信号后的修正；它的特定模型结果不应被延伸为对未来自纠错能力的永久否定。[9]

6.4 只展示最后五个赞同，会制造选择后的共识

如果用户换问法、换模型或反复生成，直到收集到五个赞同，再把先前的反对和弃权删除，呈现出来的事件已经改变。它不再是“事先固定的五个系统都赞同”，而是“多次尝试中至少有一组都赞同”。

在表 1 的 $r = 0.3$ 示例中，面对假命题，一组五系统全部赞同的概率为 6.0224%。如果假定各组之间独立，尝试 20 组，至少遇到一组错误共识的概率为 $1 - (1 - 0.060224)^{20} = 71.13\%$。这是展示筛选影响的设定计算；现实重复查询可能相关，不能直接套用该数字。

问题不在于任何可选停止规则都会破坏贝叶斯推理。若保留完整观察序列，并正确建模采样与报告机制，可以进行一致的更新。真正危险的是**隐去失败尝试，却仍按固定一次抽样理解成功结果**。保存反对意见和查询历史因此有认识论意义，而不只是整理习惯。

7. 从“机器意见”到“我的判断”：共识的心理与制度后果

7.1 五段流畅的理由可能提高说服力，却没有增加验证

当同一结论分别以技术、经济、历史和伦理语言表述时，人容易感到它已经穿过多个知识领域的考验。但表达风格的多样性不等于证据的多样性。应当追问：这些理由是否真正支持同一个精确命题？是否只是各自证明了较弱的版本？是否由结论倒推出来？

Turpin 等发现，所测模型给出的推理解释可能没有忠实呈现影响答案的偏置。这意味着一段解释可以很合理，却不足以作为生成过程的完整证词。本文据此要求检查可验证步骤，而不把措辞丰富当作机制独立的证明。[10]

这里还有一种责任转移：使用者说“不是我个人判断，五个 AI 都认可”。从程序上看，问题如何提出、哪些模型被选中、哪些回答被保留、何时结束询问，仍由人或系统设计者决定。共识不能自动抹去这些选择，也不能代替对决定负责。

7.2 求真程序可能没有获得赞同那么舒适

让使用者先写下自己的判断、查看原始证据、解释为什么接受或拒绝 AI，可能比直接展示结论更费力。Buçinca 等的实验发现，认知强制设计能够减少其任务中的过度依赖，但最有效的设计并不一定最受参与者欢迎。该结果支持把使用体验与判断质量分别评价。[11]

因此，提升确信并不能独立证明工具有效。一个系统若让人更快接受错误答案，就可能在流畅性和满意度上取得好成绩，在认识上却造成损失。相反，发现一个尚未解决的关键争点，短期会降低确信，却可能让后续判断更可靠。

7.3 少数意见需要检验，不能被浪漫化

反对多数并不自动更接近真理。一个错误异议不会因为“勇于挑战”而获得额外真实性。应当保留的，是尚未被回答的、具体而有证据的异议。只要求系统扮演唱反调者，也可能产生为了反对而反对的论证。

Hong 与 Page 的形式模型说明，功能上的解题多样性在特定条件下具有价值。借用到 AI 时，应当寻找不同的查证路径、知识覆盖和失误模式，而不是把不同人格设定当成多样性的充分证据。能力与互补性需要同时考虑。[12]

如果一个少数系统给出可运行的反例，而多数系统只有断言，反例应获得更高权重；如果多数给出可重复的证明，少数只表示不赞同，也没有理由机械地各打五十大板。尊重分歧的意义是让证据能够改变结论。

8. 一个可操作的核验程序

根据上述分析，本文提出以下程序。这些是有理论和文献依据的建议，尚未作为完整组合进行效果验证。

第一步，固定命题和失败条件。 把“这个方案很好”改成可检验的判断，例如“在指定输入和约束下，这个算法总能产生符合条件的结果”。事先写下什么记录、反例或计算会推翻它，避免把赞同对象在讨论中悄悄变换。

第二步，保留不受他人答案影响的初答。 第一轮使用尽可能中性的提示，提供必要材料，让系统分别给出结论、依据、适用条件和不确定性。不要先展示用户希望的结论或其他系统的支持票；确实需要这些信息时，记录它们改变了什么。

第三步，追踪证据到共同源头。 对每个关键理由注明原始记录、数据版本和所做检查。五个网址若都依赖一个原始出处，就把它们连回同一证据节点。数据来源、计算过程和解释可以分开核查，避免把同一发现计算多次。

第四步，让分工产生不同检验。 一个系统核对来源，一个独立重算，一个寻找反例，一个检查适用边界，一个整理仍未解决的冲突。这样的分工不保证独立，却比只分配五种说话风格更有机会产生互补信息。若只有两个检查实际有用，就没有必要为凑足五个而增加调用。

第五步，允许无法裁决。 每次改判应指出新增了哪条证据、哪一步计算或哪项前提修正。不能消除的争点保留在最终记录里。语言流畅程度、职位角色名称和自报信心，都不能独立承担最终裁判职责。

第六步，用已知答案的同类问题校准，再决定行动。 记录该组合的准确率、全票一致时错误率、弃权覆盖率和关键错误类型；高信心是否对应低错误率，也应接受检验。校准数据不充分时，使用“已获得多份支持，但独立性与误差率未知”比精确宣称某个后验更诚实。

这一程序可以用一个虚构案例说明：五个助手都认定某算法“对所有输入都成立”，但它们引用同一篇教程。随后，一个系统构造了边界输入，程序运行后出现违反约束的结果。此时，真正推动认识进展的是可重复的反例，以及对教程适用范围的澄清；最终有几个系统接受反例，是之后的传播结果。若运行环境或测试本身有错，反例也需要再核验。

核验也有成本。低代价、可撤销的选择未必值得完整六步；影响重大或难以撤回的判断，需要更强的外部检验。行动取决于错误损失、等待代价和可逆性，不能仅由一个置信度决定。进一步询问是否值得，可以理解为：它预计减少的决策损失，能否超过检验本身的成本。这是决策框架，不是本文测得的统一阈值。

9. 怎样让本文的观点接受反驳？

本文没有实际开展以下实验。后续检验应预先固定任务集、模型版本、提示、调用与时间预算，并保留每次输出及弃权。对事实、形式推理和开放评价分别分析，不能把所有题型混成一个平均分。

至少比较五种程序：单个强模型的同预算核验、同模型多次采样、多个模型独立投票、先独立后讨论、依据第 8 节分工的证据核验。比较时控制总成本和可用工具；否则，多系统的收益可能只是更多计算或额外检索带来的收益。题目和模型选择应在评估前固定，不能事后只报告最有利组合。

同一事实材料可以配合中性、支持和反对三种立场表达，检验结论对用户态度的敏感性。独立初答与讨论终答同时保存，以区分正确意见传播、错误意见传播和没有增益的收敛。若系统需要调权重或选择组合，应使用独立校准集与保留测试集。

主要指标应包括：最终准确率；全票一致时的错误率及其覆盖率；少数正确意见被采纳的比例；错误引文被接受的比例；单位成本获得的纠错收益。若输出数值置信度，再报告校准与 Brier 分数。若未来另行研究人的判断，则应在获得适当参与授权后记录接受建议前后的正确率和信心；本稿没有招募任何参与者。

统计单位应与问题相符。重复调用和不同提示往往嵌套在同一道题下，不能将它们全部视作独立样本。可按题目进行配对比较和重采样，并明确模型选择带来的不确定性。对于有争议的人工标签，应保留标注分布，而非把多数标签无条件命名为事实真值。

这些比较允许真实的失败。如果独立投票在公平预算下稳定优于复杂核验程序，应缩减本文对程序复杂性的期待；如果讨论在没有新增外部材料时仍稳定改善结果，应研究内部已有知识如何被更好利用，不能坚持“没有新来源就没有进步”。如果提示立场对某个经过校准的系统毫无影响，就不应仅凭一般迎合研究给它扣分。框架应当帮助定位增益和失败，而非保护预设立场。

10. 限制

第一，本文是理论分析与定向综合，没有测量读者正在使用的五个 AI。单体正确率、共同分量和先验都是说明机制的设定值，不能从本文图表读出某个产品的可靠性。

第二，二元、对称、等能力模型简化了现实。多选题存在多种不同错误答案，自由生成答案还涉及语义等价、部分正确和遗漏。实际的一致性判断本身也可能有测量误差。本文模型没有估计这些复杂性。

第三，文献筛选不是穷尽性的系统综述；部分来源只核验了原始摘要，未逐项审计数据和全部附录。不同研究使用的模型、基准、工具与年份不同，不能把它们的结果拼接成统一效果量。近期预印本尤其需要继续核查。

第四，独立性不是唯一美德。共享高质量证据、合理讨论和统一采用正确证明都可能有益。本文警惕的是把这种共享产生的一致重复计数，而非主张系统应彼此隔绝，也不主张反对票越多越好。

第五，证据可追溯并不等于证据无误；原始论文、测试程序和人类判断均可能失败。本稿也由 AI 辅助形成，工具复算能约束数值错误，不能代替独立的研究判断与外部评审。

11. 结论：把赞同还原成可以检查的理由

当五个 AI 都同意我时，我有可能更接近真理。条件是：它们的赞同对真假有辨别力，尚未被已有信息解释掉的证据增量确实存在，相关错误和筛选过程得到适当处理，而结论能够接受外部检验。

我也可能只是更确信自己正确。五种语言风格、五个品牌或五轮讨论，都不能独立排除这一可能。一个没有新检验的共识，可能扩大已有理由的传播范围，却没有扩大它的证明范围。

题目最终要求我们把关注点从“有多少智能体站在我这一边”，移向“有哪些理由足以让我修正立场”。有时，答案是五份相互补充的核验；有时，是一个经得起重复的反例；还有时，是承认现有信息不足。

更接近真理的标志，是我们的判断更能经受反驳，并在证据改变时随之改变。五个 AI 的同意，只有放在这样的程序里，才知道值多少。

附录 A. 相同相关性，不同的一致可靠性

令 K 为五个系统中回答正确的个数。先按某一分布抽取 K，再在五个系统中等概率选择 K 个正确者，这就得到一个可交换的联合分布。表 2 中 A 为第 5 节 $p = 0.8, r = 0.3$ 的构造；B 在 A 的六个概率上依次增加 $0.03 \times (-1, 5/3, 0, 0, -5/3, 1)$。

表 2　解析反例。两列均为合法概率分布；行表示正确系统数，不是观测样本频数。

K	分布 A	分布 B
0	0.060224	0.030224
1	0.004480	0.054480
2	0.035840	0.035840
3	0.143360	0.143360
4	0.286720	0.236720
5	0.469376	0.499376

两列概率和均为 1，$E[K] = 4$，$E[K(K-1)] = 13.76$。因此单体正确率均为 $4/5 = 0.8$，成对同时正确概率为 $13.76/20 = 0.688$，成对相关性均为 $(0.688 - 0.8^2)/(0.8 \times 0.2) = 0.3$。但 $P(K = 5 \mid K \in \{0, 5\})$ 分别为 88.63% 和 94.29%。复现脚本对概率非负、归一化和两个矩逐项作精确检查。

材料、许可与复现

本文的概率构造无需模型 API、参与者数据或随机抽样。第 4—5 节给出模型和计算公式，附录 A 列出反例的全部概率；按精确分数枚举五个二元系统的全部 32 种模式，可以复核归一化、单体均值、成对相关性和一致条件下的正确率。本文已实际执行这些计算。计算代码、解析数据、自制图表、共享文献、证据表、术语表与修订记录保存在本地工作包；默认公开成品为完整中英文 PDF 和论文介绍。

署名为 lawyer112。本篇未额外授予全文转载、改编或其他再利用许可。外部论文的权利归原权利人，正文提供正式引文和来源链接，不重新分发其全文。

AI 使用说明

2026 年 10 月 26 日，在 Codex 环境中使用 AI 辅助检索、论证组织、起草、英译、程序编写与排版。当前会话自述模型为 GPT-6，精确服务端快照不可独立核实，因此不报告更细型号。主要来源通过原始网页核对，数值通过精确分数与枚举实际复算，两稿进行对应检查，网页与 PDF 的检查范围保存在本地核验记录中。

同一助手的改写和自查没有被记作独立审稿。文献作者的模型实验也没有被本稿重新执行。所有未开展的研究仅作为后续设计陈述。

参考文献

[1] X. Wang 等,《Self-Consistency Improves Chain of Thought Reasoning in Language Models》, 收入 *International Conference on Learning Representations*, 2023. [在线]. 载于: https://arxiv.org/abs/2203.11171v4

[2] Y. Du, S. Li, A. Torralba, J. B. Tenenbaum, 和 I. Mordatch, 《Improving Factuality and Reasoning in Language Models through Multiagent Debate》, 收入 *Proceedings of the 41st International Conference on Machine Learning*, 收入 Proceedings of Machine Learning Research, vol. 235. 2024, 页 11733～11763. [在线]. 载于: https://proceedings.mlr.press/v235/du24e.html

[3] E. M. Kim, A. Garg, K. Peng, 和 N. Garg,《Correlated Errors in Large Language Models》, 收入 *Proceedings of the 42nd International Conference on Machine Learning*, 收入 Proceedings of Machine Learning Research, vol. 267. 2025, 页 30038～30066. [在线]. 载于: https://proceedings.mlr.press/v267/kim25e.html

[4] H. K. Choi, X. Zhu, 和 S. Li, 《Debate or Vote: Which Yields Better Decisions in Multi-Agent Large Language Models?》, 收入 *Advances in Neural Information Processing Systems*, 2025. doi: 10.52202/085713-3405.

[5] M. Sharma 等, 《Towards Understanding Sycophancy in Language Models》, 收入 *International Conference on Learning Representations*, 2024. [在线]. 载于: https://arxiv.org/abs/2310.13548

[6] S. Lin, J. Hilton, 和 O. Evans, 《TruthfulQA: Measuring How Models Mimic Human Falsehoods》, 收入 *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2022, 页 3214～3252. doi: 10.18653/v1/2022.acl-long.229.

[7] G. Kohli, 《Nine Judges, Two Effective Votes: Correlated Errors Undermine LLM Evaluation Panels》. [在线]. 载于: https://arxiv.org/abs/2605.29800v1

[8] J. Lorenz, H. Rauhut, F. Schweitzer, 和 D. Helbing, 《How social influence can undermine the wisdom of crowd effect》, *Proceedings of the National Academy of Sciences*, 卷 108, 期 22, 页 9020～9025, 2011, doi: 10.1073/pnas.1008636108.

[9] J. Huang 等, 《Large Language Models Cannot Self-Correct Reasoning Yet》, 收入 *International Conference on Learning Representations*, 2024. [在线]. 载于: https://arxiv.org/abs/2310.01798v2

[10] M. Turpin, J. Michael, E. Perez, 和 S. R. Bowman, 《Language Models Don't Always Say What They Think: Unfaithful Explanations in Chain-of-Thought Prompting》, 收入 *Advances in Neural Information Processing Systems*, 2023. [在线]. 载于: https://arxiv.org/abs/2305.04388v2

[11] Z. Buçinca, M. B. Malaya, 和 K. Z. Gajos, 《To Trust or to Think: Cognitive Forcing Functions Can Reduce Overreliance on AI in AI-Assisted Decision-Making》, *Proceedings of the ACM on Human-Computer Interaction*, 卷 5, 期 CSCW1, 页 1～21, 2021, doi: 10.1145/3449287.

[12] L. Hong 和 S. E. Page, 《Groups of diverse problem solvers can outperform groups of high-ability problem solvers》, *Proceedings of the National Academy of Sciences*, 卷 101, 期 46, 页 16385～16389, 2004, doi: 10.1073/pnas.0403723101.